技术报告

基于传播树的突发事件识别

算法设计、实现过程与对照实验

摘　要

本文研究一个图级二分类问题。给定一条原帖及其完整的转发关系，模型判断该传播过程属于正常类还是突发类。实验使用 20,648 棵模拟传播树，将传播深度、层宽、直接转发比例等结构统计量与节点向量均值作为逻辑回归输入，并实现两层图同构网络，对比人工特征与消息传递两条建模路径。

在 3,098 棵独立测试树上，结构与向量合用的逻辑回归表现最好，准确率为 82.25%，宏平均 F1 为 0.7937，突发类召回率为 67.38%。该结果反映了模型对指定模拟机制的区分能力。

关键词 传播树、事件分类、结构特征、逻辑回归、图同构网络

研究问题

传播形态能提供多少分类信息？节点向量在此基础上能提供多少增益？直接学习邻接关系的图模型与统计特征模型相比，在同一划分和阈值下表现如何？

实验流程

读取三份传播树数据并校验

- 路径 A　提取结构与向量特征，拟合逻辑回归
- 路径 B　构建图批次，训练图同构网络

验证集选网络权重，测试集输出分数与误差统计

---

1 任务定义与数据表示

用 G = (V, E, X) 表示单张图。节点集合 V 按生成次序编号为 0 到 N-1，0 是原帖。边 (u, v) 从来源帖 u 指向转发帖 v。X 保存每个节点的向量。模型给每张图输出一个突发分数，标签 y 为 0 或 1。

1.1 单张图的字段

字段	类型和形状	含义
x	float32 [N, 32]	每条帖子的 32 维模拟数值
edge_index	int64 [2, N-1]	每列一条边，上行为父节点
label	int64 [1]	整棵树的标签，0 正常，1 突发

对每个非根节点 v，父节点 p(v) 在 0 到 v-1 之间。每个 v 只出现一次作为边的终点。沿父节点反复回溯时，编号严格递减且最终到达 0，因此图连通且无环，边数等于 N-1。节点编号表示生成次序，实际时长需要时间戳。

1.2 训练、验证与测试

集合	传播树	正常	突发	节点总数
训练	14,453	9,633	4,820	614,698
验证	3,097	2,064	1,033	130,964
测试	3,098	2,065	1,033	131,167

数据按整棵树划分。每类分别洗牌，约 70% 用于拟合参数，约 15% 用于挑选图网络权重，其余样本用于测试。读取器验证张量类型、数值有限性、标签取值和边约束，有生成清单时还会核对数量。

1.3 重复记录检查

读取器把节点向量和按节点编号排列的父节点数组转换为固定字节序，计算每张图的 SHA-256 指纹。同一指纹在任意集合再次出现都会触发错误。各集合的摘要还包含标签及样本顺序，可核对重建数据与本次实验是否一致。

2　模拟生成机制

2.1　节点数与父节点抽样

两类使用同一个节点数分布。令 L 服从均值 3.70、标准差 0.36 的正态分布，将 exp(L) 截断到 15 至 110 后取整数，得到节点数 N。每棵树再按类别抽取下表中的三个参数。正态分布括号内给出均值和标准差。

参数	正常类	突发类
直接连接原帖的分支概率 q	Beta(4, 13)	Beta(5, 10)
已有子节点数的偏好 γ	Normal(0.86, 0.13)	Normal(1.00, 0.13)
编号间隔衰减系数 a	Uniform(0.25, 0.75)	Uniform(0.50, 0.95)

依次生成新节点 v。以概率 q 直接连接原帖 0，其余情形在 0 到 v-1 的节点中按权重抽样，此时原帖仍在候选集合内。记 d(u) 为 u 当时已有的子节点数。父节点选定后，将它的 d(u) 加一。

$$w(u,\ v) = (1 + d(u))^{\gamma} \times \exp\left[-(v-u) / (a\ v+6) \right] \tag{1}$$

抽样概率为 w(u, v) 除以当前所有候选权重之和。当 γ 为正时，第一项提高已有转发较多的帖子的权重。第二项降低编号间隔较大的帖子的权重。类别通过参数分布影响传播形态，同时两组分布存在重叠。

2.2　节点向量

先为每张图抽取一个共享向量 t，再为每个帖子抽取独立的标准正态噪声向量 e。各向量均为 32 维，t 的初始分量独立服从均值 0、标准差 0.48 的正态分布。用固定方向 b 给 t 加上 0.20(2y-1)b。b 的前六个分量是 [1.0, -0.8, 0.7, 0.6, -0.7, 0.5]，其余为 0。

$$x_v = 0.7\ e_v + 0.5\ t \tag{2}$$

原帖向量的第七个分量额外加 0.25。共享向量让同一树内的帖子具有共同信号，类别偏移让向量本身带有可分类信息。生成器使用固定种子 20261108，节点向量属于模拟数值。

3　结构特征与向量汇聚

读取父节点数组后，按节点编号升序计算深度。根节点深度为 0，每个子节点的深度等于父节点深度加一。对父节点编号计数得到出度 d(v)，对深度计数得到每层宽度 w(k)。

$$\text{depth}(0) = 0，\text{depth}(v) = \text{depth}(p(v)) + 1 \tag{3}$$

3.1　七项结构特征

特征	计算规则
节点数	N
最大深度	所有节点深度的最大值
平均深度	所有节点深度之和除以 N
最宽层占比	最大的层宽 w(k) 除以 N
原帖直接转发比例	根节点出度 d(0) 除以 N-1
最大出度比例	最大的 d(v) 除以 N-1
叶节点比例	出度为 0 的节点数除以 N

有向树的密度等于边数除以 N(N-1)，在这里化简成 1/N，因此密度只重复节点数的信息。固定维度下，恢复父节点之后的深度计算、出度计数和层宽计数都可以线性完成。

3.2　节点向量均值

$$m(G) = (x_0 + x_1 + \cdots + x_{N-1}) / N \tag{4}$$

m(G) 是 32 维向量。将七项结构特征和 m(G) 按列拼接，得到 39 维图级输入。

3.3　四节点手算

若边为 0→1、0→2、2→3，则深度是 [0, 1, 1, 2]，出度是 [2, 0, 1, 0]，三层宽度是 [1, 2, 1]。按表中顺序，结构特征是 [4, 2, 1, 1/2, 2/3, 2/3, 1/2]。模型每次处理的是这样的一整棵树。

4　逻辑回归与对照方法

先将每张树转成固定长度的向量，再用逻辑回归输出突发分数。对每一种输入组合，均值 μ 和标准差 σ 只在训练集上估计，随后用同一组参数变换训练、验证和测试向量。

$$z_j = (f_j - \mu_j) / \sigma_j \tag{5}$$

若训练集某列方差为零，标准化器用 1 作为该列的缩放因子。模型对 z 做线性加权，再用 S 形函数得到 0 到 1 之间的分数。

$$s = b + \Sigma_j w_j z_j，p(y=1 \mid z) = 1 / (1 + \exp(-s)) \tag{6}$$

拟合最小化二元交叉熵与权重平方惩罚之和。实现使用 L2 正则、C=1.0 和 L-BFGS 求解，最多迭代 400 次。四种输入分别拟合，预测时取标签 1 对应的一列分数。

$$L = \Sigma_i [-y_i \log p_i - (1-y_i) \log(1-p_i)] + (\Sigma_j w_j^2) / (2C) \tag{7}$$

4.1　对照与特征消融

方法	输入	维数
多数类基线	突发分数恒为 0	-
节点数基线	只输入传播树的节点数	1
图结构	输入七项结构统计量	7
节点向量均值	输入图内节点的均值向量	32
结构与向量合用	按列拼接结构统计量与均值向量	39

节点数基线用于检验图大小本身的区分力。其余三个对照依次回答结构能提供多少信息、节点向量能提供多少信息，以及二者合用能否继续提升分类表现。

4.2　实现顺序

```
for each feature set:
    fit StandardScaler and LogisticRegression on train
    score val and test with predict_proba(X)[:, 1]
    predict burst only when score > 0.5
```

5　图同构网络

5.1　双向边与根节点标记

对每条原始转发边补一条反向边，消息因此可以在来源与转发帖之间双向流动。在 32 维节点向量后拼接一维根标记，原帖为 1，其余为 0，形成 33 维输入。原始方向用于计算第 3 节的结构特征。

5.2　两轮邻域求和

图同构网络使用邻域求和聚合 [1, 2]。设 h 为节点表示，本项目固定自项系数为 1。每轮先把节点自己的表示与所有邻居表示相加，再通过多层感知机和整流函数更新。

$$a_v = h_v + \Sigma_{u\ 为\ v\ 的邻居}\ h_u，h'_v = \mathrm{ReLU}(\mathrm{MLP}(a_v)) \tag{8}$$

模块	输入与输出	计算
图卷积第 1 层	33 → 64 → 64	求和、两层线性变换与整流
图卷积第 2 层	64 → 64 → 64	重复一轮，参数独立
全局均值汇聚	N × 64 → 64	每棵图分别对节点取均值
分类头	64 → 64 → 2	两层线性变换，中间整流

两层卷积后，一个节点的表示可接收至多两跳邻域的信息。全局均值将任意大小的树压成一个 64 维图向量。分类头给出正常与突发两个未归一化分数，评估时通过 Softmax 转为概率。默认结构共有 18,946 个可训练参数。

5.3　批次如何装图

图加载器把最多 128 棵树拼成一个不相连的大图，并对每棵树的边索引增加节点偏移。批次向量 batch 为每个节点记录其所属的图，均值汇聚据此把节点分组。这样可并行处理多棵树，同时每次聚合只沿所在树的边进行。

5.4　前向计算

```
x = batch.x
for conv in convs:
    x = relu(conv(x, batch.edge_index))
return head(global_mean_pool(x, batch.batch))
```

6　训练、模型选择与评估

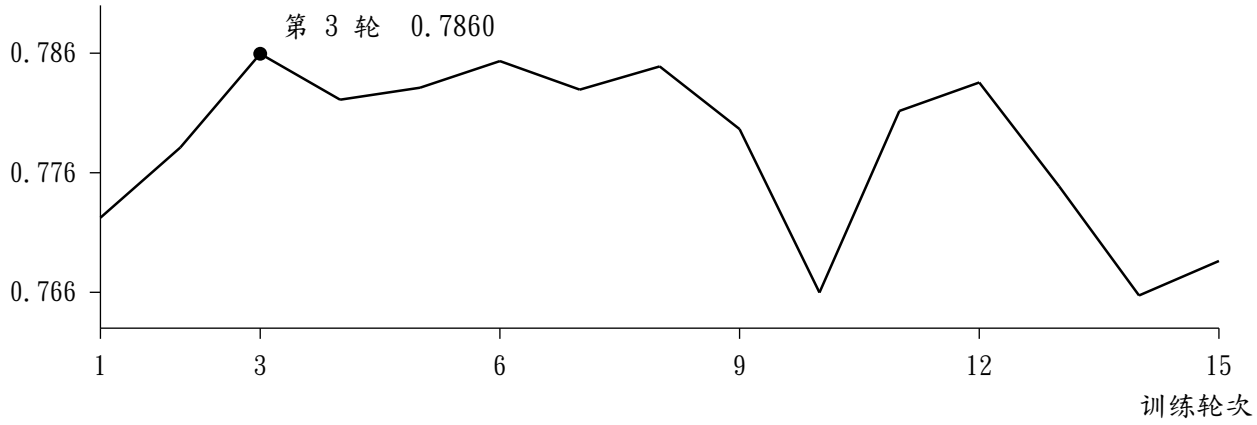
6.1　训练和权重选择

图同构网络使用 Adam，学习率 0.001，训练 15 轮，批大小 128，训练时打乱图的顺序。每批对两类未归一化分数计算交叉熵，清空梯度、反向传播，再更新权重。训练日志按每批包含的图数对损失加权，得到每轮每图平均损失。下式中 B 是该批图数。

$$L_{\text{batch}} = -\left(\sum_{g} \log p_g(y_g)\right) / B \tag{9}$$

每轮结束后在验证集上计算宏平均 F1。只有严格超过此前最佳值才保存权重，平分时保留更早一轮。全部轮次完成后恢复最佳权重，再对测试集打分。逻辑回归按固定设置训练。

图 1　图同构网络的验证集宏平均 F1



最佳权重取自第 3 轮。每图平均训练损失由 0.5419 降到 0.3411，而验证分数在后续轮次波动。

6.2　指标

突发分数严格大于 0.5 时判为突发。准确率是判对的样本占比。对任一类，TP 是正确识别数，FP 是误报数，FN 是漏报数。精确率为 TP/(TP+FP)，召回率为 TP/(TP+FN)，分母为零时记作 0。

$$F1 = 2TP / (2TP + FP + FN)，\text{宏平均 } F1 = (F1_{\text{正常}} + F1_{\text{突发}}) / 2 \tag{10}$$

ROC-AUC 衡量突发分数的排序能力。平均精确率 AP 按召回率增量加权各阈值处的精确率。这两个指标用连续分数计算。

7　结果与误差分析

表 1　同一划分下的对照结果

方法	验证 F1	测试 F1	准确率	突发召回	AUC	AP
多数类	0.3999	0.4000	0.6666	0.0000	0.5000	0.3334
仅节点数	0.3999	0.4000	0.6666	0.0000	0.4880	0.3262
图结构	0.6721	0.6642	0.7308	0.4279	0.7665	0.6248
节点向量均值	0.7543	0.7331	0.7773	0.5557	0.8351	0.7160
结构与向量合用	0.8076	0.7937	0.8225	0.6738	0.8859	0.7991
图同构网络	0.7860	0.7598	0.7960	0.6118	0.8500	0.7523

表中的 F1 均为宏平均，准确率、召回率、AUC 和 AP 均在测试集计算。多数类基线的准确率约为 67%，却漏掉全部突发样本。只用节点数时，排序指标也接近随机，符合两类共享节点数分布的设定。

表 2　结构与向量合用的测试混淆矩阵

真实类别	判为正常	判为突发
正常	1,852	213
突发	337	696

模型正确识别 696 个突发样本，漏报 337 个，并将 213 个正常样本误报为突发。突发精确率为 696/(696+213) = 76.57%，突发召回率为 696/(696+337) = 67.38%。

7.1　两类输入提供了什么

在训练集中，正常类与突发类的平均最大深度分别为 4.90 和 4.10，平均原帖直接转发比例分别为 38.25% 和 51.60%。结构单独使用时测试宏平均 F1 为 0.6642。与仅用向量相比，合用结构后的 F1 提升约 0.0606，说明两类输入在本实验中互补。图同构网络的测试 F1 为 0.7598，这个结果与当前的汇聚、训练设置和模拟分布绑定。

7.2　适用范围

节点向量带有模拟器设定的类别偏移，类别差异也体现在生成的树形。结果来自一次固定划分和训练种子，适用于完整传播树的模拟分类。实际传播速度需要时间戳。研究提前识别时，应先固定观测截止时刻，再用截断后的传播图和独立定义的真实事件标签重新评估。

8 工程实现与复现

8.1 从程序入口追到模型

代码文件	关键职责
generate_dataset.py	抽样、分层划分并写入三份张量文件
cascades.py	校验树、恢复父节点、构建特征矩阵
train_gnn.py	构建图批次、训练、选权重并预测
run_experiments.py	运行两条建模路径、评估与导出

入口的 main 调用 load_dataset 读取样本。event_classification 调用 matrices 准备逻辑回归输入，再调用 run_gin 得到图网络分数。classification_metrics 对两类模型统一计分。实现对应仓库提交 be12bfa。

8.2 运行命令

```
python -m pip install -r requirements.txt
cd experiments/weibo_cascades
python generate_dataset.py --out data
python run_experiments.py
```

三份现有张量文件可通过 --data-dir 指定。默认结果写入 run/，也可用 --out 修改目录。metrics.json 保存划分指纹、指标及逐轮日志，event_test_predictions.csv 逐图保存真实标签和各模型分数，gin_model.pt 保存验证集最佳图网络权重。

运行设置为 CPU、训练种子 42。记录的软件版本为 Python 3.12.14、NumPy 2.3.5、PyTorch 2.6.0+cpu、PyTorch Geometric 2.6.1 与 scikit-learn 1.8.0。

参考文献与实现文档

[1] Xu K, Hu W, Leskovec J, Jegelka S. How Powerful are Graph Neural Networks? ICLR, 2019. arXiv:1810.00826.

[2] PyTorch Geometric 2.6.1. GINConv operator documentation.